

Desviaciones respecto del protocolo pre-registrado

Componente empírico · Sistema CarniCore · Enfoque 2

Registro OSF: <https://osf.io/yp7t3> · Registrado el 2 de agosto de 2026

Protocolo de referencia: 06_Experimento/protocolo.pdf, versión 1.0

Ubicación en el repositorio: 06_Experimento/osf_deviations.pdf

Versión 1.0 · Elaborado para la entrega del examen final (semana 19)

1. Propósito y alcance

La Sección 7.3 de la guía de la Entrega 4 (2B) exige documentar cada desviación del análisis efectivamente ejecutado respecto del plan pre-registrado en OSF, con la razón, el momento en que se detectó y la mitigación aplicada. Este documento cumple esa exigencia y se replica en la sección *Deviations from pre-registration* del propio registro OSF.

Actualizar el registro con las desviaciones no invalida el pre-registro. Al contrario: es la práctica que el uso maduro del pre-registro exige¹. Lo que sí invalidaría el trabajo sería ejecutar un análisis distinto del registrado y no declararlo.

2. Resumen ejecutivo

El plan de análisis pre-registrado se ejecutó **íntegramente**. Se registran dos desviaciones menores (DEV-01 y DEV-02) y una corrección documental de gravedad mayor (COR-01) relativa a cómo se reportaron los resultados en una versión preliminar del manuscrito.

ID	Naturaleza	Detectada	Efecto sobre las conclusiones
DEV-01	Ampliación del corpus de 25 a 27 RF	21/08/2026	Ninguno; extensión aditiva verificable
DEV-02	Ubicación de las notas de desacuerdo	01/09/2026	Ninguno; material suplementario
COR-01	Reporte erróneo en el manuscrito preliminar	03/09/2026	Corregido; ver Sección 5
DEV-03	Corpus <code>rf27.json</code> desactualizado respecto del ERS v2.0	03/09/2026 (detectado) 14/09/2026 (corregido)	Ninguno sobre la conclusión; ver Sección 5 bis

3. DEV-01 — Ampliación del corpus de 25 a 27 requisitos

Qué se registró. El protocolo versión 1.0 (Sección 7, Población) declara como población los 25 requisitos funcionales del ERS/SRS vigente al 2 de agosto de 2026.

Qué se ejecutó. El análisis se aplicó sobre 27 requisitos.

Razón. El comité de control de cambios del proyecto aprobó dos requisitos adicionales con posterioridad al registro: RF-26 (vista pública de trazabilidad por código QR con campos delimitados) y RF-27 (filtrado de reportes gerenciales por proveedor). Excluirlos habría analizado un corpus que ya no correspondía a la especificación vigente.

¹Nosek, B. A., Ebersole, C. R., DeHaven, A. C. y Mellor, D. T. (2018). The preregistration revolution. *PNAS*, 115(11), 2600–2606.

Momento de detección. 21 de agosto de 2026, al cerrar la versión 2.0 del ERS/SRS.

Mitigación. La extensión es puramente aditiva: los 25 requisitos originales se conservan sin alteración alguna. Esto se verificó de forma mecánica comparando `rf25.json` contra `rf27.json` antes de que `rf25.json` se eliminara como parte de la mitigación de DEV-03 (ver `07_Datos/desviaciones.md`): los 25 primeros elementos resultaron idénticos campo a campo.

Efecto sobre las conclusiones. Ninguno. El detector no marcó ningún requisito ni entre los 25 originales ni entre los 2 añadidos.

4. DEV-02 — Ubicación de las notas interpretativas de desacuerdo

Qué se registró. La Sección 9, paso 6 del protocolo prevé redactar una nota interpretativa breve por cada requisito en que el detector y el consenso experto difieran.

Qué se ejecutó. Las cuatro notas (RF-08, RF-17, RF-21 y RF-22) se redactaron, pero se publican como material suplementario en el paquete Zenodo y no en el cuerpo del artículo.

Razón. Restricción de extensión del formato de la conferencia objetivo.

Momento de detección. 1 de septiembre de 2026, al maquetar el manuscrito.

Mitigación. Las notas se incluyen íntegras en el paquete de replicación y se referencian explícitamente desde la sección de resultados del manuscrito.

Efecto sobre las conclusiones. Ninguno.

5. COR-01 — Corrección de un reporte erróneo en el manuscrito preliminar

Este apartado no documenta una desviación del plan de análisis, sino un error de reporte que se detectó y se corrigió. Se declara con el mismo detalle por transparencia.

Qué ocurrió. La versión del manuscrito circulada el 1 de septiembre de 2026 contenía tres afirmaciones incorrectas:

1. Declaraba que la fase comparativa contra el panel experto no se había ejecutado por indisponibilidad de evaluadores, y que en consecuencia no podían calcularse precisión ni exhaustividad.
2. Reportaba que el detector había marcado 1 de 27 requisitos (3,7%), atribuyendo la activación a RF-27 por el término *correspondientes*.
3. Incluía entrecomillado un fragmento de RF-27 que no corresponde al texto real de ese requisito en el ERS/SRS v2.0.

Qué era cierto en realidad, y desde cuándo. Las tres afirmaciones eran falsas ya en el momento de escribirse. El panel de tres personas expertas se ejecutó, sus etiquetas individuales estaban versionadas en `06_Experimento/datos_procesados/etiquetas_expertos.csv`, y los guiones de análisis habían producido `kappa_resultados.json`, `matriz_confusion_prf1.json` y `bootstrap_ic95.json` con las cifras correctas. El detector marcó **0 de 27** requisitos, no 1. El texto real de RF-27 no contiene el término *correspondientes*.

Cómo se detectó. Mediante auditoría del repositorio contra los artefactos del pipeline: al ejecutar `run_all.py` sobre un clon limpio, la salida (0/27) no coincidía con la cifra del manuscrito (1/27). La matriz de confusión publicada en el propio folleto de defensa lo confirmaba de forma aritmética: con $VP = 0$ y $FP = 0$ el detector no puede haber marcado ningún requisito.

Causa raíz. Las figuras y tablas del manuscrito se habían producido manualmente, sin ningún guion que las generase a partir de los datos. No existía, por tanto, ningún mecanismo que hiciera fallar la construcción cuando el documento y los datos divergían.

Mitigación aplicada.

1. El manuscrito se reescribió reportando las cifras reales: detector 0/27; consenso experto 4/27 (RF-08, RF-17, RF-21, RF-22); matriz de confusión $VP = 0$, $FP = 0$, $FN = 4$, $VN = 23$; precisión, exhaustividad y F_1 iguales a 0,0000; κ de Fleiss 0,2636; κ de Cohen por pares 0,3478, 0,3571 y 0,0870.
2. Se añadió el guion `05_generar_figuras.py`, que genera todas las figuras y todas las tablas de resultados del manuscrito directamente desde los artefactos del pipeline. El manuscrito las incorpora con `\input`, de modo que ninguna cifra puede ya escribirse a mano sin que la discrepancia sea evidente.
3. Se eliminó la cita entrecomillada inexistente.

Efecto sobre las conclusiones. Sustancial y en la dirección correcta. El resultado real es más informativo que el reportado erróneamente: el detector no coincide con el consenso experto en ningún caso, y el propio panel muestra un acuerdo bajo, lo que obliga a discutir simultáneamente el límite del detector y la estabilidad del criterio de referencia.

5 bis. DEV-03 — El corpus `rf27.json` no coincidía con el ERS entregado

Qué se registró. El README del paquete de datos afirmaba que `rf27.json` es una salida regenerada de forma determinista desde `01_ERS/ERS_SRS_2B_v2.0.tex`, y que el pipeline es reproducible de extremo a extremo desde la fuente del ERS.

Qué se ejecutó en realidad. `rf27.json` se mantenía a mano desde la Entrega 3 (2A). No recogía las precisiones (umbrales, rangos, condiciones y aprobaciones de CCB) incorporadas al ERS en la versión 2.0.

Momento de detección. 3 de septiembre de 2026, en auditoría interna del equipo, que comparó argumento por argumento cada `\rfitem` del `.tex` contra el JSON. Resultado: 21 de los 27 requisitos no coincidían.

Causa raíz. Se escribió un extractor determinista (`07_Datos/scripts/extraer_rf_desde_tex.py`) inmediatamente después de la auditoría, pero no se llegó a ejecutar sobre el corpus real antes de la entrega evaluada el 13 de septiembre de 2026: el README quedó afirmando una regeneración que no había ocurrido.

Mitigación aplicada, 14/09/2026. Se ejecutó `extraer_rf_desde_tex.py -salida rf27.json` sobre el `.tex` vigente y se reejecutó `run_all.py` de punta a punta sobre un clon limpio. Las cifras publicadas (κ de Fleiss 0,2636; matriz de confusión $VP = 0$, $FP = 0$, $FN = 4$, $VN = 23$; bootstrap IC95; análisis de potencia) son **idénticas byte a byte** a las obtenidas con el corpus anterior: el detector congelado se ejecutó sobre ambas versiones y no marcó ningún requisito en ninguna de las dos.

Efecto sobre las conclusiones. Ninguno. El hallazgo es de veracidad documental (el README afirmaba una regeneración que no se había hecho), no de validez de los resultados publicados.

6. Elementos del protocolo que NO se desviaron

Se deja constancia expresa de que los siguientes elementos se ejecutaron tal como fueron registrados, sin cambio alguno:

- Las tres categorías de patrón del detector y su lista completa de expresiones regulares, fijadas antes de conocer las etiquetas expertas.
- La regla de decisión del detector: un requisito se marca si activa al menos una categoría.
- La regla de consenso del panel: mayoría simple, al menos 2 de 3.
- El conjunto de métricas: κ de Cohen por pares, κ de Fleiss, matriz de confusión, precisión, exhaustividad y F_1 .
- El procedimiento de intervalos de confianza: *bootstrap* no paramétrico de 10.000 réplicas con semilla fija igual a 42.
- El carácter ciego e independiente de la clasificación experta.

7. Trazabilidad

Este documento se genera desde `06_Experimento/osf_deviations.tex` y se versiona junto al resto del repositorio. Su contenido se replica en el apartado *Deviations from pre-registration* del registro <https://osf.io/yp7t3>.

Aprobado por el equipo CarniCore: Castro, Crespo, Gamarra, Pérez y Quintero.