

Un detector léxico-sintáctico de ambigüedad no replica el juicio experto sobre requisitos funcionales en español: estudio de caso en trazabilidad cárnica

Ariel O. Castro Bazaña^[0009-0005-1575-8935], Kleber O. Crespo
Espinoza^[0009-0000-9145-1357], Edhu X. Gamarra
Araujo^[0009-0001-8312-9656], Carlos A. Pérez Ruiz^[0009-0003-6741-9391], and
Erick J. Quintero Gende^[0009-0000-6032-4179]

Universidad Técnica Estatal de Quevedo (UTEQ),
Facultad de Ciencias de la Computación, Quevedo, Los Ríos, Ecuador
`{acastrob,kcrespoe,egamarraa,cperezr3,equinterog}@uteq.edu.ec`

Abstract. Contexto. Los detectores automáticos de ambigüedad en requisitos se han validado casi exclusivamente sobre corpus en inglés. Se desconoce su comportamiento sobre requisitos funcionales (RF) escritos en español en dominios agroindustriales latinoamericanos. **Objetivo.** Medir en qué grado un detector determinista basado en reglas léxico-sintácticas replica el juicio de un panel experto sobre los 27 RF de CarniCore, un sistema real de trazabilidad cárnica en Ecuador. **Método.** Estudio de caso con censo completo del corpus y protocolo pre-registrado en OSF. Un detector de tres categorías (cuantificadores vagos, conjunciones múltiples y voz pasiva sin agente) se contrastó contra el consenso por mayoría simple de tres personas expertas que clasificaron los mismos RF de forma ciega e independiente. Se calcularon κ de Cohen por pares, κ de Fleiss, matriz de confusión, precisión, exhaustividad y F_1 , con intervalos de confianza al 95 % por *bootstrap* de 10.000 réplicas. **Resultados.** El detector no marcó ningún requisito (0/27). El panel marcó cuatro por consenso (RF-08, RF-17, RF-21 y RF-22). La matriz de confusión resultante es VP = 0, FP = 0, FN = 4, VN = 23, con precisión, exhaustividad y F_1 iguales a 0,0000. El acuerdo interno del panel fue bajo: κ de Fleiss de 0,2636 y κ de Cohen por pares entre 0,0870 y 0,3571. La diferencia de prevalencia entre detector y panel no alcanza significación con este tamaño de corpus (McNemar exacta, $p = 0,1250$). **Conclusiones.** El resultado nulo tiene dos lecturas simultáneas y ambas son informativas: el detector léxico no captura la ambigüedad que los expertos señalan, que es semántica y pragmática; y el propio constructo “requisito ambiguo” resulta poco reproducible entre evaluadores. Publicamos el corpus, las etiquetas de los tres evaluadores y los guiones de análisis para que el contraste pueda replicarse.

Keywords: Ambigüedad en requisitos · Detección automática · Requisitos funcionales · Acuerdo inter-evaluador · Estudio empírico · Ecuador.

1 Introducción

Las distribuidoras de productos cárnicos en Ecuador gestionan la trazabilidad animal con registros manuales, lo que dificulta acreditar el cumplimiento sanitario ante la autoridad competente. CarniCore digitaliza esa cadena mediante 27 RF redactados en español que cubren registro de proveedores, ingreso de lotes, cadena de frío, pesaje y consulta pública por código QR [33], con atributos de calidad especificados según ISO/IEC 25010:2023 [32]. La calidad léxica de esos requisitos condiciona la calidad del diseño y de las pruebas: la ambigüedad no detectada propaga defectos aguas abajo [23,22].

La detección automática de ambigüedad se ha estudiado principalmente sobre corpus en inglés [24,20,27,4]. Las herramientas pioneras del área —ARM [54] y QuARS [18]— establecieron el enfoque de reglas léxicas que este trabajo evalúa, y Kiyavitskaya et al. [38] fijaron los requisitos que debe cumplir una herramienta de este tipo. La revisión sistemática de Cheng et al. [9] sobre inteligencia artificial generativa aplicada a la ingeniería de requisitos, y el trabajo de Arora et al. [2], coinciden en que la evidencia disponible procede de sistemas de países de renta alta y en inglés. No hemos encontrado estudios que apliquen un detector a un corpus en español de un dominio agroindustrial latinoamericano, ni que contrasten esa salida contra un panel experto en ese contexto.

Un segundo vacío, menos discutido, es el del criterio de referencia. La mayoría de las evaluaciones de detectores asume que el juicio experto es un patrón oro estable, pero rara vez reporta el acuerdo interno de ese panel [35,46]. Si el criterio de referencia es poco reproducible, las métricas de exactitud diagnóstica que se calculan contra él heredan esa inestabilidad.

Este trabajo aporta: (1) un detector de reglas de código abierto para ambigüedad léxico-sintáctica en español; (2) la primera medición, hasta donde alcanza nuestra revisión, del contraste entre ese detector y un panel experto sobre un corpus real en español del dominio de trazabilidad cárnica, reportando también el acuerdo interno del panel; y (3) un paquete de replicación FAIR [53] con el corpus, las etiquetas individuales de los tres evaluadores y los guiones de análisis.

RQ1. ¿Con qué exactitud diagnóstica replica el detector léxico-sintáctico el consenso de un panel experto sobre los 27 RF de CarniCore?

RQ2. ¿Qué grado de acuerdo alcanzan entre sí las personas expertas al clasificar esos mismos requisitos, y qué implica ese grado para la interpretación de RQ1?

2 Trabajo relacionado

Seguimos el esquema abreviado de Kitchenham y Charters [37], con las actualizaciones de Petersen et al. [43] para la extracción y clasificación. La cadena de búsqueda `("requirements" AND ("ambiguity" OR "smells") AND ("detection" OR "NLP"))` se ejecutó sobre Scopus, IEEE Xplore y ACM DL con ventana 2003–2026; de 148 resultados se revisaron 31 a texto completo y se retuvieron los 12 más cercanos. La Tabla 1 resume los seis principales.

Table 1. Trabajos más cercanos y diferencia con este estudio.

Referencia	Año	Idioma	Método	Diferencia con este trabajo
Ferrari y Esuli [24]	2019	EN	PLN dominio cruzado	No español; no reporta κ del panel
Femmer et al. [20]	2017	DE/EN	Reglas (<i>smells</i>)	No español; corpus industrial cerrado
Gervasi et al. [27]	2019	EN	Taxonomía	Sin detector aplicado
Berry et al. [4]	2003	EN	Manual de ambigüedad	Sin evaluación empírica
Fischbach et al. [25]	2023	EN	PLN + LLM	Pruebas de aceptación, no ambigüedad
Ezzini et al. [17]	2022	EN	Anáfora + corpus	Una sola clase de ambigüedad
Este trabajo	2026	ES	Reglas + panel	Español, agroindustria, κ del panel publicado

Ferrari y Esuli [24] alcanzan $F_1 \geq 0,70$ con modelos de procesamiento de lenguaje natural para ambigüedad de dominio cruzado en inglés. Femmer et al. [20] formalizan doce *smells* de requisitos detectables por reglas y los aplican a documentación industrial alemana e inglesa. Gervasi et al. [27] y Berry et al. [4] aportan taxonomías de ambigüedad sin detector aplicado. Fischbach et al. [25] combinan procesamiento de lenguaje natural y modelos de lenguaje para derivar pruebas de aceptación. Ezzini et al. [17] y, antes, Yang et al. [56] atacan específicamente la ambigüedad anafórica. Gleich et al. [28] y Tjong y Berry [51] publican detectores de reglas comparables al nuestro, ambos sobre corpus en inglés y sin contraste contra un panel con acuerdo reportado.

Ninguno de esos trabajos opera sobre español, ninguno reporta el acuerdo interno del panel que usa como referencia y ninguno publica el corpus etiquetado por evaluador individual. Ese es el nicho que ocupa este estudio.

3 Método

3.1 Diseño y PICOC

Estudio de caso holístico simple con censo completo del corpus [44,57], reportado según la plantilla de Jedlitschka et al. [34] y el cuerpo de conocimiento SWE-BOK v4.0 [52]. **Población:** los 27 RF verbatim del ERS/SRS v2.0 de CarniCore (Pucayacu, La Maná, Ecuador). **Intervención:** detector determinista basado en reglas. **Comparación:** consenso por mayoría simple (≥ 2 de 3) de un panel de tres personas expertas en ingeniería de requisitos. **Resultado:** exactitud diagnóstica del detector frente al consenso, y acuerdo inter-evaluador del panel.

Contexto: proyecto de fin de curso de pregrado, UTEQ, julio a septiembre de 2026.

3.2 Corpus y trabajo de campo

El corpus procede de un ERS elaborado en tres rondas de campo sobre la empresa cliente: 16 entrevistas semiestructuradas grabadas en vídeo y audio (227 minutos acumulados) con siete perfiles operativos, un cuestionario respondido por 31 personas de seis roles y construido según la lista de verificación de Molléri et al. [40], cinco documentos originales de la organización y cinco sesiones de *walkthrough* de validación. El número de entrevistas se fijó con el criterio de saturación de significado de Hennink et al. [30] y la interpretación de los resultados se contrastó con participantes del propio estudio conforme a Birt et al. [5]. Todo el trabajo de campo se ejecutó bajo consentimiento informado conforme a la Ley Orgánica de Protección de Datos Personales del Ecuador [3]; el material identificable permanece en un contenedor cifrado con AES-256 fuera del depósito abierto y solo se publican transcripciones seudonimizadas.

3.3 Detector

El detector (`detector_ambigüedad.py`) aplica tres reglas sobre el texto verbatim en español de cada RF, derivadas de las categorías de Femmer et al. [20] y del manual de Berry et al. [4]:

- C1 – Cuantificadores vagos.** Términos cuyo referente no es verificable sin contexto adicional (*algunos, varios, adecuado, suficiente, correspondiente*, entre otros; 26 patrones).
- C2 – Conjunciones múltiples.** Más de tres conectores *y/o*, o más de dos verbos modales en el mismo requisito, como indicio de requisito compuesto.
- C3 – Voz pasiva sin agente.** Perífrasis pasiva o pasiva refleja sin agente explícito, que compromete la verificabilidad [33].

Un RF se marca como ambiguo si activa al menos una categoría. El análisis es determinista y reproducible desde el corpus publicado.

3.4 Panel experto

Tres personas con experiencia en ingeniería de requisitos clasificaron los 27 RF como ambiguo o no ambiguo de forma ciega e independiente, sin acceso a la salida del detector, usando una rúbrica común incluida en el material suplementario. El acuerdo se cuantificó con κ de Cohen para cada par [10] y κ de Fleiss para el conjunto [26], con las bandas interpretativas de Landis y Koch [39]. El consenso se fijó por mayoría simple antes de conocer los resultados, conforme al protocolo registrado.

3.5 Plan de análisis y desviaciones

El protocolo se registró en OSF (<https://osf.io/yp7t3>) el 2 de agosto de 2026, antes de la clasificación experta y de la ejecución del detector [41]. El registro previo es la salvaguarda contra el *p-hacking* [48] y contra la formulación de hipótesis después de conocer los resultados [36]. El plan pre-registrado comprende estadística descriptiva, matriz de confusión frente al consenso, precisión, exhaustividad y F_1 , κ de Cohen y de Fleiss, e intervalos de confianza al 95% por *bootstrap* de 10.000 réplicas con semilla fija [15], siguiendo las prácticas de investigación computacional reproducible [45,42]. Se ejecutó íntegramente. Se registran dos desviaciones:

DEV-01. El corpus creció de 25 a 27 RF tras la aprobación de RF-26 y RF-27 por el comité de control de cambios, con posterioridad al registro. El detector se aplicó sin modificación al corpus ampliado; los 25 RF originales se conservan sin alteración y la extensión fue puramente aditiva, lo que se verificó comparando `rf25.json` contra `rf27.json` antes de que el primero se eliminara al mitigar DEV-03 (ver `07_Datos/desviaciones.md`).

DEV-02. El protocolo contemplaba una nota interpretativa por cada desacuerdo entre detector y consenso. Las cuatro notas se redactaron con posterioridad al análisis y se incluyen como material suplementario, no en el cuerpo del artículo, por restricción de extensión.

Una versión anterior de este manuscrito, circulada internamente el 1 de septiembre de 2026, declaraba erróneamente que la fase comparativa no se había ejecutado. Esa declaración era incorrecta: el panel se ejecutó, las métricas se calcularon y sus salidas estaban versionadas en el repositorio desde esa misma fecha. Se deja constancia de la corrección por transparencia.

3.6 Análisis de sensibilidad estadística

Dado que el estudio es un censo de tamaño fijo, no procede un cálculo de potencia *a priori* ni una potencia observada, que sería redundante con el valor p [31]. Se reporta en su lugar un análisis de sensibilidad: qué magnitud de efecto habría sido detectable con $N = 27$, $\alpha = 0,05$ y potencia 0,80, y qué N se requeriría para efectos de interés (Tabla 5). El cálculo canónico de referencia (d de Cohen = 0,50, $\alpha = 0,05$, $1 - \beta = 0,80$) [11,6] se incluye en esa misma tabla.

4 Resultados

4.1 RQ1: exactitud diagnóstica del detector

El detector no activó ninguna de las tres categorías sobre ninguno de los 27 RF (Tabla 2, Fig. 1). El panel marcó cuatro requisitos por consenso: RF-08 (cálculo de vida útil con cuatro umbrales por tipo de producto), RF-17 (georreferenciación opcional de la granja de origen), RF-21 (sincronización de operaciones

Table 2. Activaciones del detector por categoría sobre los 27 RF de CarniCore.

Categoría de patrón	RF que la activan	Porcentaje
C1 – Cuantificadores vagos	0/27	0.0%
C2 – Conjunciones múltiples	0/27	0.0%
C3 – Voz pasiva sin agente	0/27	0.0%
Al menos una categoría	0/27	0.0%

Table 3. Matriz de confusión del detector frente al consenso experto (mayoría simple (≥ 2 de 3 expertos)) y métricas de exactitud diagnóstica con intervalo de confianza al 95 % por *bootstrap* (10000 réplicas, semilla 42).

	Consenso: ambiguo	Consenso: no ambiguo
Detector: ambiguo	VP = 0	FP = 0
Detector: no ambiguo	FN = 4	VN = 23
Precisión = 0.0000 (IC 95 %: [0.0000, 0.0000])		
Exhaustividad = 0.0000 (IC 95 %: [0.0000, 0.0000])		
F_1 = 0.0000 (IC 95 %: [0.0000, 0.0000])		

fuera de línea) y RF-22 (devolución total o parcial con reingreso o baja según estado).

La matriz de confusión resultante (Tabla 3, Fig. 2) es VP = 0, FP = 0, FN = 4, VN = 23. Precisión, exhaustividad y F_1 valen 0,0000, con intervalos de confianza al 95 % por *bootstrap* degenerados en [0,0000, 0,0000]: ninguna remuestra de los 27 RF produce un solo acierto, porque el detector no emite ningún positivo.

Conviene separar dos lecturas. El detector no produce falsos positivos, lo que en un filtro de primer paso es deseable. Pero tampoco produce verdaderos positivos, de modo que su valor informativo frente a este panel es nulo: no aporta ninguna decisión que el equipo no tuviera ya.

4.2 RQ2: acuerdo interno del panel

El acuerdo del panel fue bajo (Tabla 4, Fig. 3). El κ de Fleiss para los tres evaluadores es 0,2636, dentro de la banda *acceptable* de Landis y Koch [39] pero en su tercio inferior. Los pares muestran una dispersión notable: 0,3478 entre los evaluadores 1 y 2, 0,3571 entre 1 y 3, y 0,0870 entre 2 y 3, este último apenas por encima del azar.

4.3 Sensibilidad estadística

La diferencia de prevalencia entre detector y consenso descansa sobre cuatro pares discordantes, todos en la misma dirección; la prueba de McNemar exacta arroja $p = 0,1250$, por encima de $\alpha = 0,05$. Se necesitan al menos seis discordantes unidireccionales para alcanzar significación, lo que a la tasa de discordancia observada equivale a un corpus de unos 41 RF.

El menor κ detectable con $N = 27$ y potencia 0,80 es 0,5230; el κ observado (0,2636) queda por debajo de ese umbral, de modo que el acuerdo del panel no




Fig. 1. Activaciones por categoría del detector sobre los 27 RF. Generada por 05_generar_figuras.py a partir de dataset_consolidado.csv.




Fig. 2. Clasificación por requisito. La serie del detector es plana en cero; los cuatro positivos corresponden al consenso experto.

es estadísticamente distinguible del azar con este tamaño de corpus. Alcanzar un acuerdo moderado ($\kappa = 0,40$) con potencia 0,80 exigiría del orden de 47 RF. Por último, la exhaustividad se estima sobre solo cuatro positivos: aun con cero aciertos, su intervalo exacto al 95 % llega hasta 0,6024.

5 Discusión


5.1 Implicaciones para la investigación

El resultado admite dos lecturas simultáneas y ninguna de las dos puede descartarse con estos datos.

La primera es sobre el detector. Los cuatro requisitos que el panel marcó no contienen ninguno de los marcadores léxicos buscados: RF-08 es ambiguo porque enumera cuatro umbrales de vida útil sin especificar qué ocurre con tipos

Table 4. Acuerdo inter-evaluador del panel de 3 personas expertas sobre los 27 RF. Bandas interpretativas de Landis y Koch (1977).

Comparación	κ	Banda
Experto 1 vs. Experto 2	0.3478	aceptable
Experto 1 vs. Experto 3	0.3571	aceptable
Experto 2 vs. Experto 3	0.0870	leve
κ de Fleiss (conjunto)	0.2636	aceptable

**Fig. 3.** Acuerdo inter-evaluador con las bandas de Landis y Koch.

de producto no listados; RF-21 lo es porque no define el comportamiento ante conflictos de sincronización. Es ambigüedad de alcance y de intención, no de léxico. Un detector de superficie no puede alcanzarla por diseño, y este hallazgo delimita empíricamente ese techo sobre un corpus real.

La segunda es sobre el criterio de referencia. Con κ de Fleiss de 0,2636 y un par en 0,0870, el propio constructo “requisito ambiguo” resulta poco reproducible entre evaluadores. Esto invita a leer con cautela las métricas de exactitud publicadas en la literatura del área cuando no van acompañadas del acuerdo interno de su panel, una omisión que encontramos en los seis trabajos más cercanos de la Tabla 1 y que es coherente con lo observado en otros contextos de juicio experto en ingeniería de software [46,35].

5.2 Implicaciones para la práctica

Primero, una plantilla de redacción de voz activa con umbrales cuantitativos explícitos —la que el equipo aplicó al escribir el ERS— parece suprimir la ambigüedad léxica en origen: cero activaciones sobre 27 RF. Si eso se confirma en réplicas, el esfuerzo de calidad se desplaza de la herramienta al momento de la escritura.

Segundo, un detector de reglas puede seguir siendo útil como filtro barato de primer paso sobre corpus heredados o redactados sin plantilla, pero no debe

Table 5. Análisis de sensibilidad estadística del diseño ($\alpha = 0,05$, potencia objetivo $1 - \beta = 0,80$).

Parámetro	Valor
Requisitos evaluados (censo completo)	27
Prevalencia de ambigüedad según consenso	0.1481
Pares discordantes (detector vs. consenso)	4
McNemar exacta, p bilateral	0.1250
Discordantes mínimos para $p < 0,05$	6
Corpus equivalente a esa tasa (RF)	41
κ mínimo detectable con $N = 27$	0.5230
κ de Fleiss observado	0.2636
N necesario para detectar $\kappa = 0,40$	47
IC 95 % exacto de la exhaustividad	[0.0000, 0.6024]
Referencia de la guía: n por grupo ($d = 0,50$)	63

presentarse como sustituto de la inspección. En este corpus habría dado una falsa señal de tranquilidad sobre cuatro requisitos que sí requieren aclaración.

Tercero, para equipos que evalúen detectores: midan y publiquen el acuerdo de su panel antes de calcular exactitud contra él.

5.3 Hallazgo contraintuitivo y lecciones aprendidas

Esperábamos un resultado intermedio y obtuvimos ceros en las tres métricas. La tentación de presentar el estudio como fallido fue real, y de hecho una versión preliminar de este manuscrito llegó a omitir la comparación. La lección, para otros equipos de investigación empírica en pregrado [21], es que un cero bien medido, con su matriz de confusión y su análisis de sensibilidad, es un resultado; una omisión no lo es. Registrar el protocolo antes de ver los datos fue lo que hizo evidente la discrepancia.

6 Amenazas a la validez

Se organizan según Wohlin et al. [55], con al menos dos amenazas por categoría, su mitigación y la limitación remanente, atendiendo a la discusión de Siegmund et al. [47] sobre el equilibrio entre validez interna y externa en ingeniería de software empírica.

Validez interna. (i) *Cobertura del léxico del detector:* los patrones fueron fijados antes de ver las etiquetas expertas y no se ajustaron después, pero términos vagos no incluidos en la lista pasarían inadvertidos; mitigado publicando la lista completa de 26 patrones para su escrutinio. (ii) *Contaminación del panel:* los evaluadores podrían haber inferido el criterio del detector; mitigado entregándoles únicamente el texto de los requisitos, sin identificadores, prioridad ni fuente, y sin la salida del detector. Limitación remanente: dos de los tres evaluadores conocían el dominio del sistema.




Fig. 4. Potencia del contraste $\kappa \neq 0$ frente al tamaño del corpus.

Validez de constructo. (i) *Operacionalización de “ambiguo” como binario:* la ambigüedad es gradual y forzarla a dos niveles pierde matiz; mitigado con una rúbrica común, pero el κ bajo sugiere que la definición no fue interpretada de forma homogénea. (ii) *Consenso por mayoría simple:* con tres evaluadores, un solo cambio de voto altera el consenso de un requisito; se fijó la regla antes del análisis y se publican las etiquetas individuales para permitir reanálisis con reglas alternativas.

Validez de conclusión. (i) *Potencia:* con cuatro discordantes, McNemar exacta no alcanza significación ($p = 0,1250$) y el κ mínimo detectable (0,5230) supera al observado; los intervalos se reportan y no se declara significación alguna. (ii) *Prevalencia baja:* la exhaustividad se estima sobre cuatro positivos y su intervalo exacto llega a 0,6024, de modo que no puede descartarse que un detector moderadamente sensible produjera este resultado por azar. Ambas limitaciones son intrínsecas al tamaño del corpus.

Validez externa. (i) *Un solo sistema y un solo dominio:* 27 RF de una distribuidora cárnica ecuatoriana no generalizan a otros dominios ni a otros estilos de redacción; mitigado publicando el corpus íntegro para réplica. (ii) *Efecto de la plantilla de redacción:* el corpus fue escrito con una plantilla de voz activa que probablemente suprime los patrones buscados, de modo que el resultado podría no trasladarse a corpus heredados; se declara explícitamente como condición de contorno del hallazgo.

7 Conclusiones y trabajo futuro

RQ1. El detector léxico-sintáctico no replica el consenso experto sobre este corpus: 0 de 27 requisitos marcados frente a 4 del panel, con precisión, exhaustividad y F_1 iguales a 0,0000. No produce falsos positivos, pero tampoco información utilizable.

RQ2. El acuerdo interno del panel es bajo (κ de Fleiss 0,2636; pares entre 0,0870 y 0,3571) y no distinguible del azar con $N = 27$. La exactitud diagnóstica de RQ1 debe leerse contra un criterio de referencia que es él mismo inestable.

Contribuciones consolidadas. Se entrega un detector de reglas de código abierto para español; la primera medición conocida del contraste detector frente a panel sobre un corpus en español del dominio agroindustrial, con el acuerdo del panel reportado; y un paquete de replicación FAIR con las etiquetas individuales de cada evaluador, que ningún trabajo de los revisados publica.

Trabajo futuro. (1) Ampliar el corpus a los 47 RF que el análisis de sensibilidad señala como necesarios para detectar un acuerdo moderado. (2) Sustituir el detector de reglas por un modelo de lenguaje sobre el mismo corpus publicado, midiendo si alcanza la ambigüedad semántica que las reglas no alcanzan. (3) Replicar el diseño con un panel de al menos cinco evaluadores y una escala ordinal en lugar de binaria, para comprobar si el acuerdo mejora al relajar la dicotomía. (4) Extender el análisis a los requisitos no funcionales del sistema, en particular a los derivados de la normativa de protección de datos [1] y a los de explicabilidad de los dos componentes de aprendizaje automático de CarniCore [8,7,29].

Disponibilidad de datos y materiales

Paquete de replicación (corpus de 27 RF en JSON, etiquetas individuales de los tres evaluadores, transcripciones seudonimizadas, respuestas del cuestionario, guiones de análisis en Python y matriz de trazabilidad): <https://doi.org/10.5281/zenodo.22225854>, bajo CC BY 4.0 para los datos y MIT para el código, siguiendo los principios FAIR [53] y de citación de software de Force11 [49]. Pre-registro del protocolo: <https://osf.io/yp7t3>. El repositorio declara su cita recomendada en formato Citation File Format [14] y su madurez FAIR se autoevaluó con el modelo de la Research Data Alliance [19]. Código fuente archivado en Software Heritage [12,13]: `sw:h:1:dir:5741b167af89a201c815b061cc965309d8167069`. Repositorio: https://github.com/gleiston-guerrero/CarniCore_Proyecto_ISR401.git.

Uso de tecnologías asistidas por inteligencia artificial

Durante la preparación de este trabajo se utilizó un modelo grande de lenguaje (Anthropic Claude) para pulir la redacción de párrafos cuyo contenido fue escrito previamente por las personas autoras, y para revisar el formato L^AT_EX, conforme a las políticas editoriales de Elsevier [16] y Springer Nature [50].

Ningún resultado, cifra, tabla, figura o conclusión fue generado por el modelo: todas las cifras de este documento proceden de los guiones versionados en `06_Experimento/scripts_analisis/` ejecutados sobre los datos crudos publicados. Las personas autoras revisaron el texto resultante y asumen la responsabilidad íntegra de su contenido.

Agradecimientos

Agradecemos a las personas trabajadoras de la distribuidora de cárnicos de Pucayacu, cantón La Maná, provincia de Cotopaxi, que participaron en las entrevistas y en las sesiones de validación, y a las tres personas evaluadoras que integraron el panel experto. Trabajo supervisado por el PhD. Gleiston Cicerón Guerrero Ulloa, asignatura Ingeniería de Requerimientos (ISR-401), UTEQ, período 2026–2027 PPA.

References

1. Orlando Amaral, Sallam Abualhaija, Mehrdad Sabetzadeh, and Lionel C. Briand. A model-based conceptualization of requirements for compliance checking of data processing against GDPR. In: *2021 IEEE 29th International Requirements Engineering Conference Workshops (REW)*, pp. 16–20, 2021.
2. Chetan Arora, John Grundy, and Mohamed Abdelrazek. Advancing requirements engineering through generative AI: Assessing the role of LLMs. *Communications of the ACM*, 2024.
3. Asamblea Nacional del Ecuador. Ley orgánica de protección de datos personales. Registro Oficial Suplemento No. 459, 26 de mayo de 2021, 2021.
4. Daniel M. Berry, Erik Kamsties, and Michael M. Krieger. *From Contract Drafting to Software Specification: Linguistic Sources of Ambiguity — A Handbook*. University of Waterloo, Waterloo, ON, Canada, 2003.
5. Linda Birt, Suzanne Scott, Debbie Cavers, Christine Campbell, and Fiona Walter. Member checking: A tool to enhance trustworthiness or merely a nod to validation? *Qualitative Health Research*, 26(13):1802–1811, 2016. <https://doi.org/10.1177/1049732316654870>.
6. Stéphane Champely. *pwr: Basic functions for power analysis*, r package version 1.3-0. CRAN, 2020.
7. Larissa Chazette, Wasja Brunotte, and Timo Speith. Explainable software systems: From requirements analysis to system evaluation. *Requirements Engineering*, 27(4):457–487, 2022.
8. Larissa Chazette and Kurt Schneider. Explainability as a non-functional requirement: Challenges and recommendations. *Requirements Engineering*, 25:493–514, 2020.
9. Haoyu Cheng, Jati H. Husen, Yang Lu, Teerada Racharak, Nobukazu Yoshioka, Naoyasu Ubayashi, and Hironori Washizaki. Generative AI for requirements engineering: A systematic literature review. *Software: Practice and Experience*, 2026. <https://doi.org/10.1002/spe.3350>, Publicado en línea en noviembre de 2025.
10. Jacob Cohen. A coefficient of agreement for nominal scales. *Educational and Psychological Measurement*, 20(1):37–46, 1960. <https://doi.org/10.1177/001316446002000104>.

11. Jacob Cohen. *Statistical Power Analysis for the Behavioral Sciences*. Lawrence Erlbaum Associates, Hillsdale, NJ, USA, 2 edn., 1988.
12. Roberto Di Cosmo, Morane Gruenpeter, and Stefano Zacchiroli. Referencing source code artifacts: A separate concern in software citation. *Computing in Science & Engineering*, 22(2):33–43, 2020.
13. Roberto Di Cosmo and Stefano Zacchiroli. Software Heritage: Why and how to preserve software source code. In: *Proceedings of the 14th International Conference on Digital Preservation (iPRES 2017)*, 2017.
14. Stephan Druskat, Jurriaan H. Spaaks, Neil Chue Hong, Robert Haines, James Baker, Spencer Bliven, Egon Willighagen, David Pérez-Suárez, and Alexander Konovalov. Citation file format (version 1.2.0). Software specification archived on Zenodo, 2021.
15. Bradley Efron and Robert J. Tibshirani. *An Introduction to the Bootstrap*. Chapman & Hall/CRC, New York, NY, USA, 1994.
16. Elsevier. Publishing ethics: The use of generative AI and AI-assisted technologies in writing for Elsevier. Política editorial, 2023. Consultado en septiembre de 2026.
17. Saad Ezzini, Sallam Abualhaija, Chetan Arora, Mehrdad Sabetzadeh, and Lionel C. Briand. Automated handling of anaphoric ambiguity in requirements: A multi-solution study. In: *Proceedings of the 44th International Conference on Software Engineering (ICSE 2022)*, pp. 187–199, 2022.
18. Fabrizio Fabbrini, Mario Fusani, Stefania Gnesi, and Giuseppe Lami. The linguistic approach to the natural language requirements quality: Benefits of the use of an automatic tool. In: *Proceedings of the 26th Annual NASA Goddard Software Engineering Workshop*, pp. 97–105, 2001.
19. FAIR Data Maturity Model Working Group. FAIR data maturity model: Specification and guidelines. Tech. rep., Research Data Alliance, 2020.
20. Henning Femmer, Daniel Méndez Fernández, Stefan Wagner, and Sebastian Eder. Rapid quality assurance with requirements smells. *Journal of Systems and Software*, 123:190–213, 2017. <https://doi.org/10.1016/j.jss.2016.10.012>.
21. Daniel Méndez Fernández. Supporting requirements-engineering research that industry needs: The NaPiRE initiative. *IEEE Software*, 35(1):112–116, 2018.
22. Daniel Méndez Fernández and Stefan Wagner. Naming the pain in requirements engineering: A design for a global family of surveys and first results from Germany. *Information and Software Technology*, 57:616–643, 2015. <https://doi.org/10.1016/j.infsof.2014.05.008>.
23. Daniel Méndez Fernández, Stefan Wagner, Marcos Kalinowski, Michael Felderer, Priscilla Mafra, Antonio Vetrò, Tayana Conte, Marie-Therese Christiansson, Des Greer, Casper Lassenius, and Mika Mäntylä. Naming the pain in requirements engineering: Contemporary problems, causes, and effects in practice. *Empirical Software Engineering*, 22(5):2298–2338, 2017. <https://doi.org/10.1007/s10664-016-9451-7>.
24. Alessio Ferrari and Andrea Esuli. An NLP approach for cross-domain ambiguity detection in requirements engineering. *Automated Software Engineering*, 26(3):559–598, 2019. <https://doi.org/10.1007/s10515-019-00261-7>.
25. Jannik Fischbach, Julian Frattini, Andreas Vogelsang, Daniel Méndez, Michael Unterkalmsteiner, Andreas Wehrle, Pablo Restrepo Henao, Parisa Yousefi, Tedi Juricic, Jeannette Radduenz, and Carsten Wiecher. Automatic creation of acceptance tests by extracting conditionals from requirements: NLP approach and case study. *Journal of Systems and Software*, 197:111549, 2023. <https://doi.org/10.1016/j.jss.2022.111549>.

26. Joseph L. Fleiss. Measuring nominal scale agreement among many raters. *Psychological Bulletin*, 76(5):378–382, 1971. <https://doi.org/10.1037/h0031619>.
27. Vincenzo Gervasi, Alessio Ferrari, Didar Zowghi, and Paola Spoletini. Ambiguity in requirements engineering: Towards a unifying framework. In: *From Software Engineering to Formal Methods and Tools, and Back*, vol. 11865 of *Lecture Notes in Computer Science*, pp. 191–210. Springer, 2019.
28. Benedikt Gleich, Oliver Creighton, and Leonid Kof. Ambiguity detection: Towards a tool explaining ambiguity sources. In: *Requirements Engineering: Foundation for Software Quality (REFSQ 2010)*, vol. 6182 of *Lecture Notes in Computer Science*, pp. 218–232. Springer, 2010.
29. Martin Glinz. On non-functional requirements. In: *Proceedings of the 15th IEEE International Requirements Engineering Conference (RE 2007)*, pp. 21–26, 2007.
30. Monique M. Hennink, Bonnie N. Kaiser, and Vincent C. Marconi. Code saturation versus meaning saturation: How many interviews are enough? *Qualitative Health Research*, 27(4):591–608, 2017. <https://doi.org/10.1177/1049732316665344>.
31. John M. Hoenig and Dennis M. Heisey. The abuse of power: The pervasive fallacy of power calculations for data analysis. *The American Statistician*, 55(1):19–24, 2001. <https://doi.org/10.1198/000313001300339897>.
32. ISO/IEC. ISO/IEC 25010:2023 — systems and software engineering — systems and software quality requirements and evaluation (SQuaRE) — product quality model. Tech. Rep. 25010:2023, International Organization for Standardization; International Electrotechnical Commission, Geneva, Switzerland, 2023.
33. ISO/IEC/IEEE. ISO/IEC/IEEE 29148:2018 — systems and software engineering — life cycle processes — requirements engineering. Tech. Rep. 29148:2018, International Organization for Standardization; International Electrotechnical Commission; Institute of Electrical and Electronics Engineers, Geneva, Switzerland, 2018.
34. Andreas Jedlitschka, Marcus Ciolkowski, and Dietmar Pfahl. Reporting experiments in software engineering. In: Forrest Shull, Janice Singer, and Dag I. K. Sjøberg, eds., *Guide to Advanced Empirical Software Engineering*, pp. 201–228. Springer, London, 2008.
35. Magne Jørgensen. A review of studies on expert estimation of software development effort. *Journal of Systems and Software*, 70(1–2):37–60, 2004.
36. Norbert L. Kerr. HARKing: Hypothesizing after the results are known. *Personality and Social Psychology Review*, 2(3):196–217, 1998. <https://doi.org/10.1207/s15327957pspr02034>.
37. Barbara Kitchenham and Stuart Charters. Guidelines for performing systematic literature reviews in software engineering. Tech. Rep. EBSE-2007-01, Keele University and Durham University Joint Report, United Kingdom, 2007.
38. Nadzeya Kiyavitskaya, Nicola Zeni, Luisa Mich, and Daniel M. Berry. Requirements for tools for ambiguity identification and measurement in natural language requirements specifications. *Requirements Engineering*, 13(3):207–239, 2008.
39. J. Richard Landis and Gary G. Koch. The measurement of observer agreement for categorical data. *Biometrics*, 33(1):159–174, 1977. <https://doi.org/10.2307/2529310>.
40. Jefferson Seide Molléri, Kai Petersen, and Emilia Mendes. An empirically evaluated checklist for surveys in software engineering. *Information and Software Technology*, 119:106240, 2020. <https://doi.org/10.1016/j.infsof.2019.106240>.
41. Brian A. Nosek, Charles R. Ebersole, Alexander C. DeHaven, and David T. Mellor. The preregistration revolution. *Proceedings of the National Academy of Sciences*, 115(11):2600–2606, 2018. <https://doi.org/10.1073/pnas.1708274114>.

42. Roger D. Peng. Reproducible research in computational science. *Science*, 334(6060):1226–1227, 2011. <https://doi.org/10.1126/science.1213847>.
43. Kai Petersen, Sairam Vakkalanka, and Ludwik Kuzniarz. Guidelines for conducting systematic mapping studies in software engineering: An update. *Information and Software Technology*, 64:1–18, 2015. <https://doi.org/10.1016/j.infsof.2015.03.007>.
44. Per Runeson and Martin Höst. Guidelines for conducting and reporting case study research in software engineering. *Empirical Software Engineering*, 14(2):131–164, 2009. <https://doi.org/10.1007/s10664-008-9102-8>.
45. Geir Kjetil Sandve, Anton Nekrutenko, James Taylor, and Eivind Hovig. Ten simple rules for reproducible computational research. *PLoS Computational Biology*, 9(10):e1003285, 2013. <https://doi.org/10.1371/journal.pcbi.1003285>.
46. Martin Shepperd, David Bowes, and Tracy Hall. Researcher bias: The use of machine learning in software defect prediction. *IEEE Transactions on Software Engineering*, 40(6):603–616, 2014.
47. Janet Siegmund, Norbert Siegmund, and Sven Apel. Views on internal and external validity in empirical software engineering. In: *Proceedings of the 37th International Conference on Software Engineering (ICSE 2015)*, pp. 9–19, 2015.
48. Joseph P. Simmons, Leif D. Nelson, and Uri Simonsohn. False-positive psychology: Undisclosed flexibility in data collection and analysis allows presenting anything as significant. *Psychological Science*, 22(11):1359–1366, 2011. <https://doi.org/10.1177/0956797611417632>.
49. Arfon M. Smith, Daniel S. Katz, and Kyle E. Niemeyer. Software citation principles. *PeerJ Computer Science*, 2:e86, 2016. <https://doi.org/10.7717/peerj-cs.86>.
50. Springer Nature. Editorial policies: Artificial intelligence (AI). Política editorial, 2023. Consultado en septiembre de 2026.
51. Sri Fatimah Tjong and Daniel M. Berry. The design of SREE — a prototype potential ambiguity finder for requirements specifications and lessons learned. In: *Requirements Engineering: Foundation for Software Quality (REFSQ 2013)*, vol. 7830 of *Lecture Notes in Computer Science*, pp. 80–95. Springer, 2013.
52. Hironori Washizaki. Guide to the software engineering body of knowledge (SWEBOK), version 4.0. Tech. rep., IEEE Computer Society, Los Alamitos, CA, USA, 2024.
53. Mark D. Wilkinson, Michel Dumontier, IJsbrand Jan Aalbersberg, Gabrielle Appleton, Myles Axton, Arie Baak, Niklas Blomberg, Jan-Willem Boiten, Luiz Bonino da Silva Santos, and Philip E. Bourne. The FAIR guiding principles for scientific data management and stewardship. *Scientific Data*, 3:160018, 2016. <https://doi.org/10.1038/sdata.2016.18>.
54. William M. Wilson, Linda H. Rosenberg, and Lawrence E. Hyatt. Automated analysis of requirement specifications. In: *Proceedings of the 19th International Conference on Software Engineering (ICSE 1997)*, pp. 161–171, 1997.
55. Claes Wohlin, Per Runeson, Martin Höst, Magnus C. Ohlsson, Björn Regnell, and Anders Wesslén. *Experimentation in Software Engineering*. Springer, Berlin, Heidelberg, 2012.
56. Hui Yang, Anne De Roeck, Vincenzo Gervasi, Alistair Willis, and Bashar Nuseibeh. Analysing anaphoric ambiguity in natural language requirements. *Requirements Engineering*, 16(3):163–189, 2011.
57. Robert K. Yin. *Case Study Research and Applications: Design and Methods*. SAGE Publications, Thousand Oaks, CA, USA, 6 edn., 2018.